

DuDoUFNet: Dual-domain under-to-fully-complete progressive restoration network for simultaneous metal artifact reduction and low-dose CT reconstruction

Zhou, Bo and Chen, Xiongchao and Xie, Huidong and Zhou, S Kevin and Duncan, James S and Liu, Chi

摘要

为了降低患者受到辐射的潜在风险,低剂量计算机断层扫描 (low-dose computed tomography, LDCT) 已在临床实践中广泛采用,它的特点是通过降低管电流和管电压来降低放射剂量。根据低剂量协议, LDCT 图像质量通常会因不同级别的噪声而降低。当患者有金属植入物时,图像质量将进一步下降,图像会出现额外的条纹伪影以及进一步放大的噪声水平,从而影响医学诊断和其他 CT 相关应用。以前的研究主要集中在不考虑金属植入物或全剂量 CT 金属伪影减少 (metal artifact reduction, MAR) 的情况下对 LDCT 进行降噪。直接将以前的 LDCT 或 MAR 方法应用于同时减少金属伪影和低剂量 CT (MARLD) 的问题可能会产生次优的重建结果。在这项工作中,我们为 MARLD 开发了一个名为 DuDoUFNet 的双域 under-to-fully-complete 渐进式恢复网络。我们的 DuDoUFNet 旨在使用两阶段渐进恢复网络设计,通过渐进正弦图到图像域恢复来重建具有显著降低噪声和伪影的图像。我们的实验结果表明,我们的方法可以提供高质量的重建,在各种低剂量和金属设置下优于以前的 LDCT 和 MAR 方法。

关键词: 医学图像; 深度学习; 金属伪影校正

1 引言

X 射线计算机断层扫描 (CT) 是一种非侵入性成像技术,用于可视化患者的内部结构,已成为医学诊断的常见检查之一。由于 CT 在临床实践中的使用越来越多,人们对患者的总辐射剂量提出了担忧。因此,希望降低 CT 辐射剂量。最常见的方法包括降低工作电流/电压和缩短 X 射线管的曝光时间。然而,较弱的 X 射线通量水平导致正弦图具有较高的泊松噪声,从而产生具有低信噪比 (SNR) 的重建图像。对于金属植入物的患者,例如脊柱植入物和髋关节假体,由于这些高衰减物体引起的光束硬化效应,图像质量进一步下降,在 CT 中给定多色 X 射线谱,低能 X 射线光子比剩余的高能光子更容易衰减。具体来说,正弦图中金属迹线区域中的投影数据不像单色 X 射线那样遵循简单的指数衰减,因此在重建过程中会产生额外的金属伪影。非理想的图像质量不仅会严重影响诊断目的的图像质量,而且还会影响依赖 CT 的其他医疗程序,例如放射治疗中的剂量计算和 PET/SPECT 衰减校正。带有金属植入物的低剂量 CT 示例如图 1 所示。随着金属植入物的使用日益增多以及人们对降低 CT 辐射剂量的兴趣,如何在低剂量环境下为金属植入物患者重建高质量的 CT 图像是 CT 成像的重要研究方向。




图 1: 低剂量采集条件下金属植入物 CT 图像示例。左: 无金属全剂量 CT 图像。中: 全剂量 CT 图像叠加金属分割 (红色掩模) 进行模拟。右图: 金属植入物的低剂量 CT 图像 (1/4 剂量)。显示窗口为 $[-1000\ 1000]\text{HU}$ 。^[1]

2 相关工作

2.1 低剂量 CT(LDCT) 重建

对于低剂量 CT(LDCT) 重建, 以往的重建方法很多, 可归纳为两大类, 即基于模型的迭代重建 (MBIR) 和基于深度学习的重建 (DLR)。以往的 MBIR 方法是根据图像域的先验信息和正弦域数据的统计特性, 通过迭代最小化一个统一的目标函数, 从有噪声的正弦图中重建图像。图像先验的常见选择包括总变差 (TV) 及其变体^[2]、非局部均值和字典学习。尽管 MBIR 方法的重建质量得到了很大的改善, 但它们依赖于迭代的前向和反向投影操作, 不仅需要了解厂商特定的扫描几何结构, 而且计算量大, 因此重建时间长。

另一方面, 已经为 LDCT 开发的 DLR 方法显示出有希望的重建质量。Chen 等人^[3]首次提出使用两层卷积神经网络 (CNN) 进行 LDCT 图像去噪。后来, Chen 等人^[4]进一步发展到 RED-CNN 设计, 并显示出改进的 LDCT 图像去噪性能。Kang 等人^[5]采用了类似的方法, 但将 CNN 应用于 CT 图像的定向小波变换。Yi 等人^[6]提出在去噪网络训练中加入对抗性学习, 进一步提高去噪图像中的锐度。同样, Yang 等人^[7]提出加入 Wasserstein 基于距离的对抗性学习和感知损失以进一步提高性能。除了单独在图像域中使用 DLR 之外, Yin 等人^[8]提出使用正弦图域网络, 然后使用图像域网络进行域渐进 LDCT 去噪。但是, 以前的 LDCT 算法都没有考虑患者有金属植入物的情况, 这会进一步降低图像质量。将先前的 LDCT 方法直接应用于具有金属植入物的 LDCT 可能会导致次优的重建性能。

2.2 全剂量 CT 下的金属伪影消除 (MAR)

对于全剂量 CT 下的金属伪影消除 (MAR), 以往的方法很多, 也可归纳为两大类, 即传统的基于正弦图的校正方法和基于深度学习的校正方法。由于受金属影响的正弦图区域由于束硬化而在图像中产生非局部的金属伪影, 传统的 MAR 方法要么通过模拟 X 射线成像的物理效应来校正受金属影响的正弦图区域, 要么用估计值代替受金属影响的正弦图区域。用相邻的未受影响的正弦图的线性插值代替受金属影响的正弦图区域是一种典型的解决方案。然而, 在重建过程中, 插值值与未受影响值之间的不一致往往会导致新的伪影。为了改进金属影响区域的估计, 以前的工作也试图利用合成的先验图像的前向投影。通常, 这些方法的目的是首先根据 CT 的物理特性估计出一幅伪影消除的先验图像或正弦图, 然后利用先验信号指导正弦图的完成。例如, NMAR^[9]通过对初始重建图像进行多阈值分割

来生成先验图像。然后，在线性插值之前，利用先验图像的前向投影对正弦图进行归一化，从而改善了金属影响正弦图区域的值估计。

随着 CNN 在医学图像重建方面的最新进展，基于深度学习的 MAR 方法也被提出并显示出有希望的性能。Park 等人^[10]提议使用 UNet^[11]来修正光束硬化造成的正弦图不一致。Gjesteby 等人^[12]通过利用具有三个卷积层的 CNN 来改进正弦图数据校正，进一步改进了 NMAR^[9]。同样，Zhang 等人^[13]使用具有五个卷积层的 CNN 从多张初始伪影减少图像生成一张伪影减少图像，然后将生成的图像向前投影以帮助金属影响正弦图区域的校正。除了在正弦图中解决 MAR 之外，还有许多以前的工作是通过图像后处理来减少金属伪影。Huang 等^[14]在宫颈 CT 中使用了 CNN，其输入和输出之间存在残差连接。Wang 等^[15]利用 3D 条件对抗网络进行耳 CT 中的 MAR。Gjesteby 等人^[16]提出通过增加感知损失来进一步提高 MAR 性能。结合正弦图域和图像域，开发了双域恢复方法。Lin 等人^[17]首先提出了 DuDoNet，将正弦图域校正和图像域校正合并为一个网络。Lyu 等人^[18]通过添加双域网络中的金属掩码信息进一步改进了 DuDoNet。同样，Yu 等人^[19]发现，通过首先使用 CNN 估计先验图像，然后使用另一个 CNN 校正正弦图，具有深度正弦图完成的双域学习可以进一步提高 MAR 性能。但是，上述 MAR 算法仅解决了全剂量 CT 中的 MAR。使用 LDCT 中的 MAR，噪声和金属伪影会严重降低图像质量。虽然以前的基于 image-to-image 的 MAR 算法^{[14][15][16]}可以适应同时减少金属伪影和低剂量 CT 重建 (MARLD) 问题，但性能可能次优，因为图像质量会因噪声和金属伪影而严重降低，并且仅图像域校正可能不足。其他 MAR 算法很难直接适应 MARLD 问题，因为它们通常假设仅需要校正受金属影响的正弦图。

3 本文方法

3.1 本文方法概述

当低剂量和金属伪影这两个条件同时存在时，由于重建质量严重下降，独立的 LDCT 方法和 MAR 方法可能不适用于 MARLD。为了解决这些问题，我们为 MARLD 开发了一个 under-to-fully-complete 的渐进式恢复网络 (DuDoUFNet)。

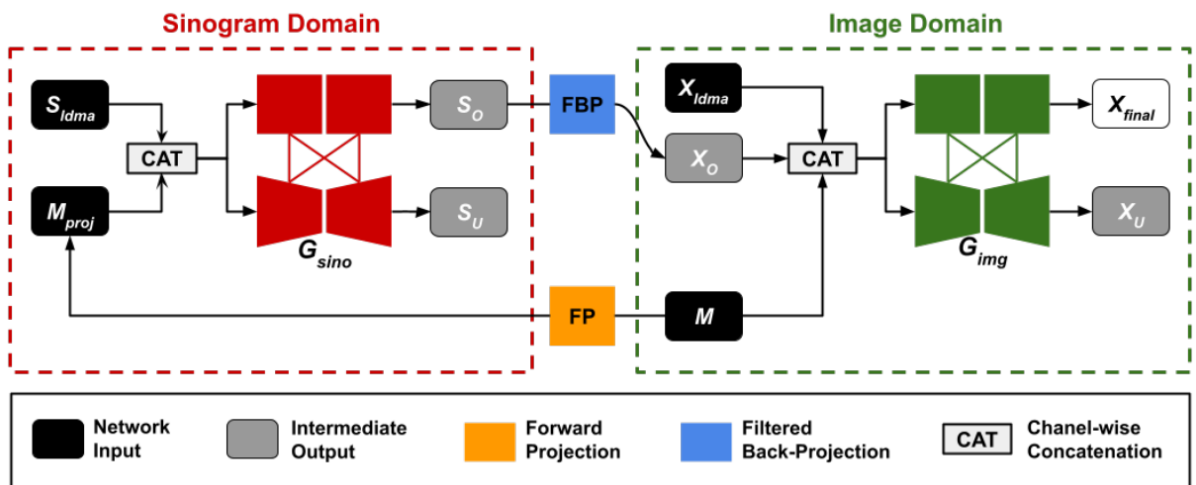


图 2: DuDoUFNet 的框架结构示意图

DuDoUFNet 的框架结构如图 2 所示。具体来说，DuDoUFNet 方法是在域和网络设计方面提出了渐进式恢复。首先，使用渐进式双域恢复。由于图像噪声和非局部金属伪影是由正弦图域中的噪声和

不一致的投影数据引起的，所以提出在正弦图域上逐步恢复信息，然后在图像域上恢复。其次，提出使用 under-to-fully-complete 的渐进式恢复网络（UFNet）进行双域恢复。将 under-complete 恢复网络和具有跨阶段连接的 fully-complete 结合起来进行渐进式恢复，其中来自 under-complete 网络的多尺度特征有助于丰富从 fully-complete 恢复到最终恢复的过程中的原始分辨率的精细特征。所提出的网络用于正弦图和图像域恢复。DuDoUFNet 以端到端的方式进行训练，损失在域渐进输出和网络渐进输出中进行监督。

DuDoUFNet 由一个正弦图域渐进式恢复网络 G_{sino} 和一个图像域渐进式恢复网络 G_{img} 组成，其中 G_{sino} 和 G_{img} 共享相同的架构（图 3），同时配置不同数量的通道输入。渐进式恢复网络是一个两阶段的网络，具有 under-complete 和 fully-complete 的恢复输出。 G_{sino} 和 G_{img} 通过过滤反投影 (Filtered Back Projection, FBP) 层^[20]45 连接，以实现双域恢复学习。

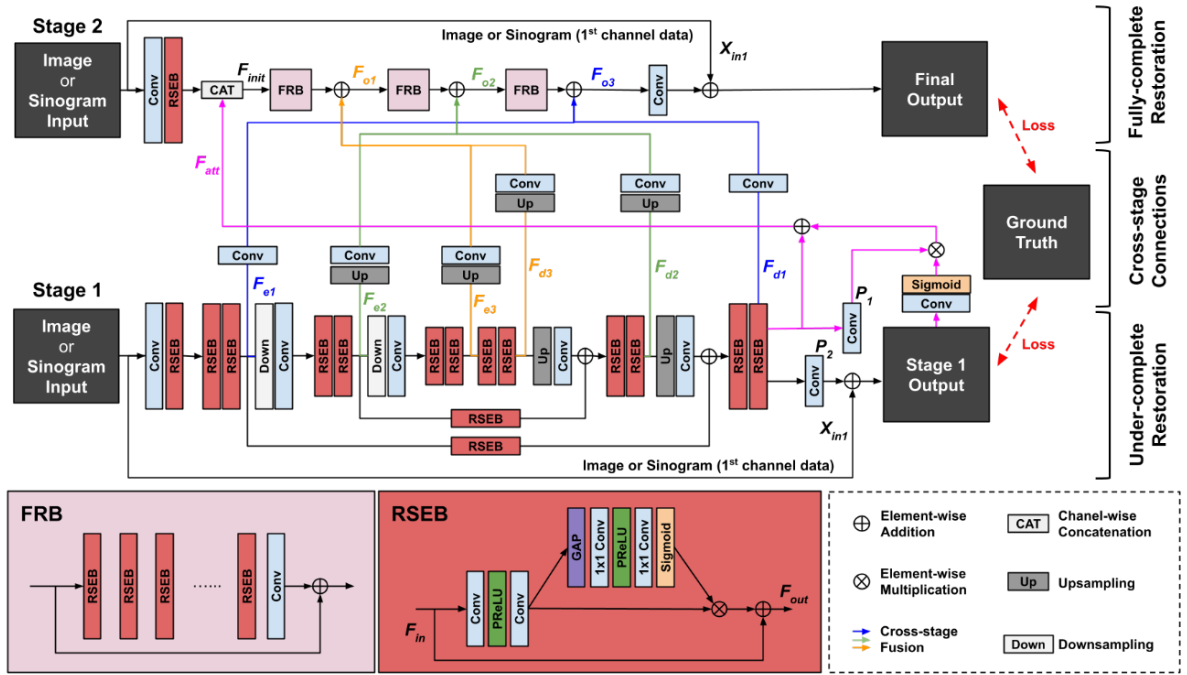


图 3: UFNet 网络结构图

由于图像域的噪声和金属伪影是由正弦图域的噪声和缺失投影数据引起的，所以提出先用正弦图恢复学习，再用图像恢复学习。鉴于低剂量金属影响的正弦图 $S_{ldma} \in \mathbb{R}^{L \times V}$ 和从金属掩模 $M \in \mathbb{R}^{H \times W}$ 向前投影的金属痕迹 $M_{project} \in \mathbb{R}^{H \times W}$ ，首先将 S_{ldma} 和 M_{proj} 连接起来，并将双通道正弦图输入 G_{sino} 进行正弦图的渐进恢复，其中 M_{proj} 指示正弦图域中的金属尺寸和位置信息。输出不完全恢复输出 S_u 和完全恢复输出 S_o 。然后，通过 FBP 层^[20]将最精细的恢复正弦图 S_o 转换为初始恢复图像 $X_o \in \mathbb{R}^{H \times W}$ ，用于进一步的图像域恢复。由于从 S_{ldma} 重建的 FBP 图像 X_{ldma} 仍然提供了正确的非金属区解剖轮廓（图 1），因此，将 X_{ldma} 和 M 用 X_o 连接起来，并将 3 通道图像输入 G_{img} 进行渐进图像恢复。与正弦（Sinogram）恢复类似， G_{img} 同时输出欠完全恢复输出 X_u 和完全恢复输出 X_{final} ，图像 X_{final} 是 DuDoUFNet 的最终重建输出。在训练期间，对 S_o 、 S_u 、 X_o 、 X_u 和 X_{final} 进行监督。

3.2 UFNet

骨干网是两级网络，称为 under-to-fully-complete progressive restoration network(UFNet)，由 under-complete restoration subnetwork(UnNet)、fully-complete restoration subnetwork(FuNet) 和跨级连接 (cross-stage connections) 组成的。UFNet 的体系结构如图 3 所示。

UFNet 基于一个 U 形网络^[11]，用于第一阶段的恢复，如图 3 底部所示。具体来说，提出了使用 residual squeeze-and-excitation block(RSEB) 来进行特征提取。给定 RSEB 的输入特征 F_{in} ，输出可以写为：

$$F_{out} = F_{in} + P_{se}[P_{ex}(F_{in})], \quad (1)$$

其中 P_{ex} 由两个卷积层组成，用于特征提取， P_{se} 是 squeeze-and-excitation^[21]，从输入特征产生信道关注，用于信道化特征重新校准。在 UnNet 中，给定输入 X_{in} ，我们首先使用带有 RSEB 的卷积层进行初始特征提取。然后，利用连续的两个 RSEB 在 UnNet 的 3 个不同层次上进行特征提取，生成 F_{e1} 、 F_{e2} 、 F_{e3} 的编码器特征和 F_{d3} 、 F_{d2} 、 F_{d1} 的解码器特征，这些特征包含适合于一般外观恢复的多尺度特征，并用于第 2 阶段恢复。UnNet 的最终输出可以写成：

$$X_u = X_{in1} + P_{fu}(F_{d1}), \quad (2)$$

其中 P_{fu} 是用于将特征通道数目减少到 1 的卷积层， X_{in1} 是 X_{in} 的第一通道数据。为了利用 UnNet 的最终监督特征进行 Stage-2 恢复，还提出了一个 self-attention connection，如图 3 中的粉红色连接所示。具体地说，自注意力特征可以通过以下方法计算：

$$F_{att} = F_{d1} + P_1(F_{d1}) \odot \sigma(P_2(X_u)), \quad (3)$$

其中 P_1 是用于生成未加权特征的 3×3 卷积层， P_2 是另一个 3×3 卷积层，其输入为 X_u ，用于生成空间方向的关注权重。注意力权重由 sigmoid 函数 σ 归一化，这样注意力权重介于 0 和 1 之间。从 UnNet 最终输出产生的空间注意力有助于在空间方向上重新校准 UnNet 最优比例尺的特征，该特征在第二阶段恢复中用作初始特征的一部分。

在使用 FuNet 的阶段 2 恢复中，如图 3 的顶部所示，给定相同的输入 X_{in} 和自注意力特征 F_{att} ，可以通过以下方式构建初始特征：

$$F_{init} = \{F_{att}, P_{init}(X_{in})\}, \quad (4)$$

其中 $\{\}$ 表示信道级联操作， P_{init} 由后跟 RSEB 的卷积层组成。然后， F_{init} 被输入到三个连续的全完备恢复块 (fully-complete restoration blocks, FRB) 中进行恢复。FRBs 的中间输出还与 UnNet 的粗到细特征融合进行恢复，利用 UnNet 的多尺度特征来辅助原始分辨率特征的恢复。该过程可制定为：

$$F_{o1} = P_{o1}(F_{init}) + P_{e3}(F_{e3}) + P_{d3}(F_{d3}), \quad (5)$$

$$F_{o2} = P_{o2}(F_{o1}) + P_{e2}(F_{e2}) + P_{d2}(F_{d2}), \quad (6)$$

$$F_{o3} = P_{o3}(F_{o2}) + P_{e1}(F_{e1}) + P_{d1}(F_{d1}), \quad (7)$$

其中 P_{o1} 、 P_{o2} 和 P_{o3} 是 FRB，它由多个 RSEB 组成，在块的输入和输出之间有残差连接。 P_{e3} 和 P_{d3} 由一个 $\times 4$ 上采样操作和一个卷积层组成（图 3 中的黄线），而 P_{e2} 和 P_{d2} 由一个 $\times 2$ 上采样操作和一个卷积层组成（图 3 中的绿线）。 P_{e1} 和 P_{d1} 只包含一个卷积层（图 3 中的蓝色线条）。最后，FuNet 的输出可以写成：

$$X_{final} = X_{in1} + P_{fo}(F_{o3}), \quad (8)$$

其中 P_{fo} 是用于将特征通道数量减少到 1 的卷积层。增加残差连接以减少梯度消失问题。在本文中，将 RSEB 的数量设置为 6，其中 FuNet 包含与 UnNet 大致相同数量的 RSEB，因此两个子网络包含相

似数量的参数。

由于 FuNet 不使用任何下采样操作，它能够保持高分辨率的特征。第一阶段的多尺度特征有助于丰富第二阶段的特征，从而有助于最终的细节恢复。

3.3 双域学习目标 (Dual-domain Learning Objective)

DuDoUFNet 学习在正弦图和图像域中恢复带有金属伪影的低剂量图像。损失函数由三部分组成，包括正弦图渐进恢复损失、中间图像损失和图像渐进恢复损失。如图 2 所示，sinogram 域损失通过以下方式直接监控 UFNet 的欠完全恢复输出和完全恢复输出：

$$\mathcal{L}_{sino} = \|S_o - S_{gt}\|_1 + \|S_u - S_{gt}\|_1, \quad (9)$$

其中 S_u 和 S_o 是未完全修复的和完全修复的正弦图。 S_{gt} 是无金属植入物的地面真实全剂量正弦图。然后，使用 FBP 层将最优恢复正弦图 S_o 转换为中间恢复图像 X_o 。中间图像损失通过以下步骤计算：

$$\mathcal{L}_{int} = \|(1 - M) \odot (X_o - X_{gt})\|_1, \quad (10)$$

其中 M 是图像域中的金属植入物分割掩模， X_{gt} 是无金属植入物的地面真实全剂量图像。通过将 X_o 输入到图像域 UFNet，图像域损失通过以下方式直接监督欠完全和完全恢复输出：

$$\mathcal{L}_{img} = \|(1 - M) \odot (X_{final} - X_{gt})\|_1 + \|(1 - M) \odot (X_u - X_{gt})\|_1, \quad (11)$$

其中 X_{final} 是我们的 DuDoUFNet 的最终恢复输出。在图像域损失中，将损失乘以 $1 - M$ 允许网络学习非金属区域中的恢复，因为金属不是我们的焦点。最后，总损失函数可以写成：

$$\mathcal{L}_{tot} = \alpha_1 \mathcal{L}_{sino} + \alpha_2 \mathcal{L}_{int} + \alpha_3 \mathcal{L}_{img}, \quad (12)$$

其中设置 $\alpha_1=5$ 和 $\alpha_2 = \alpha_3 = 1$ ，以实现最佳性能。与图像域恢复损失相比，对正弦图域恢复损失使用更高的权重，因为双域框架遵循正弦图到图像域的渐进恢复，所以图像域恢复依赖于来自正弦图恢复网络的合理恢复的正弦图。我们的 DuDoUFnet 通过优化 \mathcal{L}_{tot} 以端到端的方式进行训练。

4 复现细节

4.1 与已有开源代码对比

本文没有给出参考源代码。复现步骤：

1. 完成第一阶段 UnNet 的代码实现；
2. 完成第二阶段 FuNet 的代码实现；
3. 完成 DuDoUFNet 网络整体框架的搭建；
4. 数据处理，实现整个网络模型优化过程；
5. 对搭建的网络模型进行训练测试，并不断调试，得到最佳的训练效果；

4.2 数据准备

本文使用真实模拟的金属植入物低剂量 CT 图像进行训练和评估我们的方法。从 DeepLesion 数据集^[22]中随机挑选了 162 幅大小为 512×512 像素的全剂量 CT 二维图像，并从^[13]中收集了 100 个不同位置、形状和大小的人工分割金属植入物。然后，我们随机选取 45 幅 CT 图像和 90 个金属掩模对训练数据进行合成，因此训练集使用了 4050 张图像。其余 10 个金属面罩与其余 117 个 CT 图像配对，产生 1170 个组合进行评估。

通过在干净的 CT 图像中插入金属植入物来模拟低剂量金属影响的正弦图和相应的重建图像。更具体地说，考虑了具有 120 kVp 多能 X 射线源的等角扇束投影几何结构。在正弦图中模拟了两个带有泊松噪声的低剂量 CT 场景，分别使用 1/2 剂量水平的 2×10^5 光子入射 X 射线和 1/4 剂量水平的 1×10^5 光子入射 X 射线。对于每个图像，正弦图是通过在 0-360 度之间均匀间隔的 360 个投影视图产生的。模拟前将 CT 图像调整为 416×416 ，从而得到大小为 641×640 的正弦图。

模拟数据代码参考：<https://github.com/MIRACLE-Center/DuDoNet>

4.3 实验环境

DuDoUFNet 是用 PyTorch 实现的,用 ADAM 求解器对网络进行优化,参数为 $(\beta_1, \beta_2) = (0.5, 0.999)$, 学习速率为 $1e-4$ 。在一个 24G 内存的 NVIDIA GeForce RTX 3090 上训练了 200 个 Epoch, 批量大小为 1。

5 实验结果分析

本文使用结构相似度指数 (SSIM) 和峰值信噪比 (PSNR) 两个评价指标来衡量重建性能，这些指标是用预测重建和非金属区域的 ground truth 计算的。SSIM 侧重于结构恢复的评估，而 PSNR 侧重于强度剖面恢复的评估。

表 1: FBP 和 DuDoUFNet 在不同剂量设置下重建效果评估表

Method	1/2 dose		1/4 dose	
	PSNR	SSIM	PSNR	SSIM
FBP	23.124	0.486	22.145	0.438
DuDoUFNet	30.804	0.896	26.818	0.859

本文评估了传统的重建方法 FBP 和 DuDoUFNet 在不同低剂量设置下的重建效果，如表 1 所示，在 1/2 低剂量实验中，与原始 FBP 重建相比，DuDoUFNe 可以显著改善图像质量，SSIM 从 0.486 提高到 0.896，PSNR 从 23.124dB 提高到 30.804dB。类似的观察可以在 1/4 低剂量实验中发现，即使在降低剂量水平的情况下，DuDoUFNet 仍然保持 SSIM 为 0.859，PSNR 为 26.818。

在不同低剂量的设置下，对 DuDoUFNet 以及传统的 FBP 算法的重建结果可视化，如图 4和图 5所示。DuDoUFNet 对于 1/2 剂量的重建结果比 1/4 剂量的重建结果更好，并且，当金属植入物越小的，重建结果更好。




图 4: 1/2 剂量重建结果示意图




图 5: 1/4 剂量重建结果示意图

6 总结与展望

在这项工作中，实现了双域从欠完全到完全渐进恢复网络，DuDoUFNet，用于同时减少金属伪影和低剂量 CT 重建。该网络在域和网络设计方面的渐进修复，当低剂量获取和金属植入共存时，能够令人满意地重建。首先，继承了前人在全剂量 CT 中使用双域学习的 MAR 方法。提出了采用渐进的双域恢复方法，首先恢复正弦信号，然后恢复图像信号。首先进行正弦图恢复，因为重建图像的噪声和金属伪影主要是由正弦图域的退化投影数据引起的。一个能够恢复正弦图信号的强大网络，保持良好的细节，也是为图像域恢复提供良好的初始重建的关键。其次，提出了一个渐进的欠完全恢复网络，称为 UFNet，用于每个域的恢复。UFNet 结合了两个子网络，包括不包含下采样或上采样操作的 FuNet 和带有编码-解码操作的 UuNet。采用下采样和上采样的 UuNet 可以生成多尺度的恢复特征，而采用原始分辨率的 FuNet 可以生成聚焦于原始分辨率水平的恢复特征。然后，通过跨阶段连接将 UuNet 和 FuNet 结合起来，使我们能够为最终的恢复生成空间丰富的特征。

从实验结果中，展示了使用 DuDoUFNet 在不同低剂量设置和不同的金属插入时同时对减少金属

伪影和低剂量 CT 重建的灵活性。首先，我们可以从图 4和图 5中看到，我们的方法可以持续地优于以前的 FBP 方法，在不同的剂量设置下，我们能够将 SSIM 保持在 0.859 以上，PSNR 保持在 26.818 以上。

由于收集真实的金属插入的低剂量 CT 和无金属 CT 数据进行训练是不可行的，也没有公开的真实投影数据，我们使用真实感 CT 模拟从临床无金属全剂量 CT 图像中产生合成训练对，这是全剂量 CT MAR 和 LDCT 中常用的数据准备方法。然而，由于金属尺寸/形状/位置的有限可变性、低剂量 X 射线谱的变化以及 X 射线曝光设置的不一致等因素，模拟数据的质量可能会影响对真实数据的重建性能。今后能进一步探索如何建立更好的模拟数据集，以进一步提高对真实患者数据的重建性能。该网络的特征提取使用了通道注意力机制，改进网络的特征提取模块，可能会产生更好的结果。

参考文献

- [1] ZHOU B, CHEN X, XIE H, et al. DuDoUFNet: Dual-domain under-to-fully-complete progressive restoration network for simultaneous metal artifact reduction and low-dose CT reconstruction[J]. IEEE Transactions on Medical Imaging, 2022.
- [2] FANG R, ZHANG S, CHEN T, et al. Robust low-dose CT perfusion deconvolution via tensor total-variation regularization[J]. IEEE transactions on medical imaging, 2015, 34(7): 1533-1548.
- [3] CHEN H, ZHANG Y, ZHANG W, et al. Low-dose CT denoising with convolutional neural network[C] //2017 IEEE 14th International Symposium on Biomedical Imaging (ISBI 2017). 2017: 143-146.
- [4] CHEN H, ZHANG Y, KALRA M K, et al. Low-dose CT with a residual encoder-decoder convolutional neural network[J]. IEEE transactions on medical imaging, 2017, 36(12): 2524-2535.
- [5] KANG E, CHANG W, YOO J, et al. Deep convolutional framelet denosing for low-dose CT via wavelet residual network[J]. IEEE transactions on medical imaging, 2018, 37(6): 1358-1369.
- [6] YI X, BABYN P. Sharpness-aware low-dose CT denoising using conditional generative adversarial network[J]. Journal of digital imaging, 2018, 31(5): 655-669.
- [7] YANG Q, YAN P, ZHANG Y, et al. Low-dose CT image denoising using a generative adversarial network with Wasserstein distance and perceptual loss[J]. IEEE transactions on medical imaging, 2018, 37(6): 1348-1357.
- [8] YIN X, ZHAO Q, LIU J, et al. Domain progressive 3D residual convolution network to improve low-dose CT imaging[J]. IEEE transactions on medical imaging, 2019, 38(12): 2903-2913.
- [9] MEYER E, RAUPACH R, LELL M, et al. Normalized metal artifact reduction (NMAR) in computed tomography[J]. Medical physics, 2010, 37(10): 5482-5493.
- [10] PARK H S, LEE S M, KIM H P, et al. CT sinogram-consistency learning for metal-induced beam hardening correction[J]. Medical physics, 2018, 45(12): 5376-5384.
- [11] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image seg-

mentation[C]//International Conference on Medical image computing and computer-assisted intervention. 2015: 234-241.

- [12] GJESTEBY L, YANG Q, XI Y, et al. Deep learning methods to guide CT image reconstruction and reduce metal artifacts[C]//Medical Imaging 2017: Physics of Medical Imaging: vol. 10132. 2017: 752-758.
- [13] ZHANG Y, YU H. Convolutional neural network based metal artifact reduction in x-ray computed tomography[J]. IEEE transactions on medical imaging, 2018, 37(6): 1370-1381.
- [14] HUANG X, WANG J, TANG F, et al. Metal artifact reduction on cervical CT images by deep residual learning[J]. Biomedical engineering online, 2018, 17(1): 1-15.
- [15] WANG J, ZHAO Y, NOBLE J H, et al. Conditional generative adversarial networks for metal artifact reduction in CT images of the ear[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. 2018: 3-11.
- [16] GJESTEBY L, SHAN H, YANG Q, et al. Deep neural network for CT metal artifact reduction with a perceptual loss function[C]//In Proceedings of The Fifth International Conference on Image Formation in X-ray Computed Tomography. 2018.
- [17] LIN W A, LIAO H, PENG C, et al. Dudonet: Dual domain network for ct metal artifact reduction[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2019: 10512-10521.
- [18] LYU Y, LIN W A, LIAO H, et al. Encoding metal mask projection for metal artifact reduction in computed tomography[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. 2020: 147-157.
- [19] YU L, ZHANG Z, LI X, et al. Deep sinogram completion with image prior for metal artifact reduction in CT images[J]. IEEE Transactions on Medical Imaging, 2020, 40(1): 228-238.
- [20] ZHOU B, ZHOU S K, DUNCAN J S, et al. Limited view tomographic reconstruction using a cascaded residual dense spatial-channel attention network with projection data fidelity layer[J]. IEEE transactions on medical imaging, 2021, 40(7): 1792-1804.
- [21] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [22] YAN K, WANG X, LU L, et al. DeepLesion: automated mining of large-scale lesion annotations and universal lesion detection with deep learning[J]. Journal of medical imaging, 2018, 5(3): 036501.